

iFood

Анализ клиентской базы и маркетинговых кампаний

Портфолио-проект Junior Data Analyst

EDA · очистка данных · 10 бизнес-вопросов · Excel-дашборд

- Источник данных: ifood_df.csv (Customer Personality Analysis, маркетинговый датасет ритейлера)
- Итоговая выборка: 2 021 клиент × 36 показателей (после очистки и обогащения)
- Инструменты: Python (EDA, очистка) + Microsoft Excel (SUMIFS / AVERAGEIFS / COUNTIFS, сводные таблицы, графики)
- Дата подготовки отчёта: сентябрь 2026

О проекте и методология

Компания iFood — розничная сеть, продающая продукты питания и премиальные товары (вино, мясо, рыба, сладости, золотые изделия) через три канала: сайт, каталог и физические магазины. Компания регулярно проводит маркетинговые кампании и хочет понимать, какие клиенты приносят больше выручки, какие каналы и кампании работают эффективнее, и как удерживать ценных клиентов.

Задача проекта — провести разведочный анализ данных (EDA), очистить датасет от технических ошибок и дублей, и на основе очищенных данных ответить на 10 конкретных бизнес-вопросов, которые маркетинг-директор мог бы задать аналитику. Каждый вопрос решён в Excel с помощью формул (SUMIFS/AVERAGEIFS/COUNTIFS) и визуализирован графиком, а в этом отчёте по каждому вопросу дано обоснование выбранного метода и содержательный вывод с бизнес-рекомендацией.

Этапы работы

- **1. EDA:** изучены типы данных, распределения, пропуски и дубликаты по всем 39 исходным полям.
- **2. Очистка:** удалены 184 дубликата и 2 бесполезные константные колонки; исправлена логическая ошибка в исходном поле MntRegularProds (уходило в минус); one-hot колонки семейного статуса и образования свёрнуты в читаемые текстовые поля.
- **3. Обогащение:** добавлены расчётные признаки — TotalSpend, TotalPurchases, AvgOrderValue, возрастные и доходные группы, RFM-сегмент клиента.
- **4. Анализ в Excel:** для каждого из 10 бизнес-вопросов построена сводная таблица на формулах и график (столбчатый, линейный или круговой — в зависимости от природы вопроса).
- **5. Дашборд:** итоговые KPI и ключевые графики собраны на одном листе для быстрого обзора.

Структура клиентской базы после очистки

Показатель	Значение
Строк (клиентов) до очистки	2 205
Строк (клиентов) после очистки	2 021
Удалено точных дублей	184
Столбцов после очистки	36
Пропусков в итоговых данных	0
Средний доход клиента	51 687 у.е.
Средний чек	37.55 у.е.
Отклик на последнюю кампанию	15.4 %

Лог очистки данных

1. Дубликаты

Найдено и удалено 184 полностью идентичные строки функцией `drop_duplicates()` (совпадение сразу по всем 39 полям — случайность исключена). 2 205 → 2 021 строка.

2. Константные поля

Столбцы `Z_CostContact` и `Z_Revenue` содержали одно и то же значение во всех строках (3 и 11) — удалены как не несущие аналитической информации.

3. Пропуски

Проверка `isnull()` по всем полям — пропущенных значений не обнаружено.

4. Ошибка в исходном агрегате трат

Обнаружено, что поле `MntTotal` в исходном файле фактически равнялось сумме только 5 из 6 категорий (без золотых товаров), из-за чего производное поле `MntRegularProds = MntTotal - MntGoldProds` уходило в отрицательные значения (до -283 у.е.) для клиентов с высокими тратами на золотые товары. Оба поля удалены и заменены корректным `TotalSpend = сумма трат по всем 6 категориям`.

5. One-hot → читаемые категории

10 бинарных столбцов семейного положения и образования (`marital_*`, `education_*`) свёрнуты в 2 текстовых поля `Marital_Status` и `Education` — так удобнее строить сводные таблицы и графики; для ML-задач one-hot кодирование восстанавливается тривиально.

6. Проверка выбросов

Доход клиента (`Income`) проверен по правилу $1.5 \times IQR$ — верхняя граница выброса $\approx 117\,561$ у.е., максимум в данных 113 734 у.е.: выбросов не обнаружено. Возраст — в диапазоне 24–80 лет, аномалий нет.

7. Кросс-проверка кампаний

Сумма бинарных полей `AcceptedCmp1...AcceptedCmp5` сверена с полем `AcceptedCmpOverall` — расхождений не найдено ни в одной из 2 021 строки.

8. Новые признаки

`TotalChildren`, `TotalPurchases`, `AvgOrderValue`, `Age_Group`, `Income_Group` (квартили), `Recency_Bucket`, `Visits_Bucket`, `Segment (RFM)` — добавлены для удобной сегментации в сводных таблицах Excel.


10 бизнес-вопросов и решения

Далее каждый вопрос разобран по единой структуре: формулировка → метод расчёта в Excel → график → вывод и бизнес-рекомендация. Формулы и графики продублированы в файле iFood_Portfolio_Analysis.xlsx на листах B1-B10.

B1 Как доход клиента влияет на объём его трат?

Как посчитано (обоснование метода)

Клиенты разбиты на 4 равные по численности группы по квартилям поля Income (pandas.qcut). Для каждой группы в Excel формулой **AVERAGEIFS()** по листу «Данные» посчитаны средние суммарные траты (TotalSpend). Это стандартный способ построить сводную таблицу «категория → среднее» на формулах — таблица остаётся «живой» и пересчитывается автоматически при изменении исходных данных, в отличие от статичного экспорта из PivotTable.




Вывод и бизнес-рекомендация

Траты растут не линейно, а взрывным образом: группа Very High тратит в среднем в ≈ 16 раз больше, чем Low (1 369 против 83 у.е.). Основную выручку компании формируют верхние 50% клиентов по доходу. **Рекомендация:** приоритизировать персональные предложения и премиальные линейки товаров для High/Very High сегментов, а для Low — делать акцент на скидки и товары повседневного спроса, а не на premium-ассортимент.

В2 Какой канал продаж (сайт / каталог / магазин) наиболее востребован?

Как посчитано (обоснование метода)

Формулой **SUM()** просуммированы столбцы количества покупок по каждому из 3 каналов (NumWebPurchases, NumCatalogPurchases, NumStorePurchases) по всей базе клиентов; доля канала — покупки канала, делённые на сумму всех покупок по формуле.




Вывод и бизнес-рекомендация

Офлайн-магазин остаётся главным каналом ($\approx 46\%$ всех покупок) — почти вдвое больше, чем каталог (21%). Сайт на 2-м месте (33%). **Рекомендация:** каталог — самый слабый канал, стоит проверить экономику его поддержания либо инвестировать в его конверсию, поскольку он заметно отстаёт от двух других каналов.

В3 Клиенты с каким семейным статусом делают самый большой средний чек?

Как посчитано (обоснование метода)

AvgOrderValue (средний чек = TotalSpend / TotalPurchases, посчитан заранее в Python) усреднён формулой **AVERAGEIFS()** по каждой категории семейного положения; COUNTIF() дополнительно показывает размер каждой группы для проверки её статистической значимости.




Вывод и бизнес-рекомендация

Разброс между группами небольшой (36–44 у.е.), но вдовцы/вдовы показывают самый высокий чек — вероятно, это более взрослые и финансово устроенные клиенты с меньшим числом иждивенцев. **Вывод:** семейное положение само по себе — слабый предиктор чека; для сегментации разумнее опираться на доход и число детей (см. В1 и В5).

В4 Как уровень образования влияет на отклик на маркетинговые кампании?

Как посчитано (обоснование метода)

Response — бинарный флаг (1/0), поэтому **AVERAGEIFS()** по этому полю в разрезе Education напрямую даёт конверсию в отклик (долю единиц) — распространённый приём расчёта rate-метрик без дополнительной формулы деления.




Вывод и бизнес-рекомендация

Чёткая положительная связь: чем выше образование, тем выше отклик — от 4,1% (Basic) до 21,0% (PhD), разница почти в 5 раз. **Рекомендация:** точнее таргетировать кампании на клиентов с высшим образованием (Master/PhD) — они не только чаще откликаются, но и (см. В1) обычно относятся к более высокому доходу, что даёт двойной эффект на ROI кампании.

В5 Как количество детей в семье влияет на общие траты клиента?

Как посчитано (обоснование метода)

TotalChildren = Kidhome + Teenhome посчитан заранее в Python; в Excel **AVERAGEIFS()** агрегирует TotalSpend по каждому значению этого счётчика (0, 1, 2 или 3 ребёнка в семье).



Вывод и бизнес-рекомендация

Зависимость обратная и очень сильная: без детей клиенты тратят в среднем 1 121 у.е., с одним ребёнком — уже вчетверо меньше (473), с двумя-тремя — около 250 у.е. Вероятная причина — более высокая чувствительность к цене и меньше покупок премиальных категорий (вино, деликатесы). **Рекомендация:** для семей с детьми развивать промо на объём и товары для дома, а не premium-ассортимент.

В6 Какие категории товаров формируют основную выручку компании?

Как посчитано (обоснование метода)

Формула **SUM()** суммирует столбец трат по каждой из 6 товарных категорий по всем 2 021 клиентам. Круговая диаграмма — оптимальный тип графика для отображения соотношения «часть от целого» по структуре выручки.



Вывод и бизнес-рекомендация

Вино — безусловный лидер (более половины выручки), мясо на 2-м месте ($\approx 27\%$): вместе эти 2 категории дают почти 78% всей выручки компании. **Рекомендация:** категории вино/мясо — приоритет для управления запасами, кросс-промо и переговоров с поставщиками; золотые товары при небольшой доле стоит отдельно проверить на маржинальность — как нишевый высокомаржинальный продукт.

В7 Какая из маркетинговых кампаний показала наибольшую конверсию?

Как посчитано (обоснование метода)

Каждый столбец AcceptedCmp1...5 и Response — бинарный флаг участия/отклика; **AVERAGE()** по бинарному столбцу — это и есть его конверсия (доля единиц) без дополнительных формул деления.




Вывод и бизнес-рекомендация

Последняя кампания (Response) показала конверсию 15,4% — в 2-12 раз выше, чем любая из предыдущих пяти (1,3–7,7%). **Рекомендация:** изучить механику последней кампании (оффер, таргетинг, момент запуска) и использовать её как эталон для будущих активаций — остальные 5 кампаний были заметно менее эффективны.

В8 Как давность последней покупки (Recency) влияет на отклик на кампанию?

Как посчитано (обоснование метода)

Recency заранее разбит в Python на 10 интервалов по 10 дней; формула **AVERAGEIFS()** считает по каждому интервалу долю откликнувшихся клиентов. Линейный график лучше всего показывает тренд показателя вдоль числовой шкалы.




Вывод и бизнес-рекомендация

Зависимость чёткая и монотонно убывающая: клиенты, купившие в последние 10 дней, откликаются в 30,7% случаев, а те, кто не покупал 91–99 дней, — только в 5,2%. Recency — один из сильнейших предикторов отклика во всей базе. **Рекомендация:** в рассылках приоритизировать «свежих» клиентов (Recency < 30) — у них отклик в 2–6 раз выше; для «спящих» клиентов нужен отдельный win-back сценарий, а не стандартная кампания (см. В10).

В9 Больше визитов на сайт = больше онлайн-покупок?

Как посчитано (обоснование метода)

NumWebVisitsMonth сгруппирован в 5 интервалов ещё в Python — по «сырым» значениям график был бы зашумлён (некоторые значения представлены 1–3 клиентами). Для каждой группы **AVERAGEIFS()** считает среднее число покупок на сайте; отдельно формулой **CORREL()** посчитан коэффициент корреляции по всей базе для проверки гипотезы.



Вывод и бизнес-рекомендация


Связи почти нет: среднее число покупок держится на уровне ≈ 4 независимо от числа визитов (корреляция $-0,06$ — фактически ноль). Рост трафика на сайт сам по себе **не увеличивает продажи** — проблема не в привлечении, а в конверсии на самом сайте (юзабилити, поиск товара, оформление заказа). **Рекомендация:** инвестировать в CRO/UX сайта, а не только в привлечение дополнительного трафика.

В10 Как сегментировать клиентскую базу для удержания и допродаж (RFM)?

Как посчитано (обоснование метода)

Упрощённый RFM-подход: клиент делится по медиане Recency (свежесть) и медиане TotalSpend (ценность) на 4 квадранта — VIP (свежий + ценный), Новые/перспективные (свежий, но пока мало тратит), Группа риска (давно не покупал, но исторически ценный), Спящие (давно не покупал и мало тратил). Логика — медианный сплит в Python; в Excel **COUNTIF()/SUMIF()** считают размер и выручку каждого сегмента.

Сегментация клиентской базы (RFM-подход)



Вывод и бизнес-рекомендация

На VIP и «Группу риска» вместе приходится $\approx 1,11$ млн у.е. — более 90% всей выручки, хотя это лишь половина базы. «Группа риска» (510 клиентов, 563 тыс. у.е. выручки) — это клиенты, которые раньше много тратили, но давно не покупали: приоритет №1 для персонального win-back предложения. «Спящие» и «Новые» почти не дают выручки — для них уместны недорогие активационные механики, а не дорогой персональный маркетинг.

Итоговые бизнес-рекомендации

1. Сфокусироваться на верхних 50% клиентов по доходу

High/Very High доход даёт в 6–16 раз больше выручки на клиента (B1) — персональные предложения и премиальный ассортимент в первую очередь для них.

2. Спасти «Группу риска» до того, как они уйдут окончательно

510 клиентов, которые раньше были ценными, но давно не покупали, держат под угрозой 563 тыс. у.е. выручки (B10) — приоритетный win-back с персональным оффером.

3. Таргетировать кампании по Resensy и образованию

Response растёт в 5–6 раз для «свежих» клиентов и клиентов с высшим образованием (B4, B8) — это самые дешёвые способы поднять конверсию рассылок без изменения оффера.

4. Инвестировать в конверсию сайта, а не только в трафик

Корреляция визитов и покупок практически нулевая (B9) — рост посещаемости не даёт роста продаж; нужен CRO/UX-аудит воронки на сайте.

5. Пересмотреть роль канала «Каталог»

Каталог даёт вдвое меньше покупок, чем магазин, и заметно отстаёт от сайта (B2) — проверить рентабельность канала или перезапустить его продвижение.

6. Тиражировать механику последней кампании

Её конверсия (15,4%) в разы выше предыдущих пяти (B7) — разобрать её оффер/таргетинг и использовать как шаблон для будущих кампаний.

Полная рабочая версия анализа — с живыми формулами, сводными таблицами и графиками — доступна в файле **iFood_Portfolio_Analysis.xlsx** (листы «Обзор проекта», «Очистка данных», «Дашборд», «Данные» и B1–B10).